

金融資料採礦

期末專題報告

新北市各行政區 2018-2024
年之離婚比例變化

報告者:黃琬茹 黃薇臻 胡盼恩

日期:2026/05/28

大綱

- 一、 研究動機與目的
- 二、 資料來源與資料預處理說明
- 三、 資料採礦操作流程
- 四、 資料採礦結果說明
- 五、 遇到的問題和建議改進的方法
- 六、 結論

一、研究動機與目的

1. 研究動機:

近年來，台灣社會的家庭型態逐漸改變，離婚已不再像過去一樣被視為少見事件。隨著女性經濟能力提升、價值觀改變，以及現代人對婚姻期待提高，離婚率也成為社會中備受關注的議題。根據統計資料顯示，台灣每年都有相當數量的夫妻選擇結束婚姻，而離婚不僅影響夫妻雙方，也可能對子女教育、家庭經濟、心理健康與社會結構造成深遠影響。

2. 目的:

本研究主要目的在於探討台灣離婚比例變化，以及離婚現象對個人、家庭與社會所造成的影響。由於全台灣資料範圍較廣，為使研究內容更具聚焦性與分析深度，因此本研究以「新北市各行政區 2018 年至 2024 年間之婚姻狀況資料」作為研究對象希望透過統計資料分析近年離婚比例的趨勢，觀察不同年份以及不同行政區的離婚比例趨勢變化。

二、資料來源與資料預處理說明

1.資料來源


<https://data.gov.tw/dataset/123951>



2.資料來源預處理



原始資料筆數龐大，有從 1998 年一直到 2024 年的資料，我們只想蒐集近幾年的資料，於是只保留 2018 ~ 2024 年大約 200 筆左右的資料，其餘全刪除，並且資料提供完整並無缺失值，於是我們不需處理缺失值的問題。

三、資料採礦操作流程



總體流程說明:


本專題主要目的在於探討新北市各行政區於 2018 至 2024 年間之離婚比例是否呈現逐年上升趨勢，因此資料採礦流程設計以「建立離婚比例指標、篩選關鍵分析變數及提升模型穩定性」為核心。本研究主要使用 Altair Rapid Miner 進行資料探勘與模型的建立，首先進行資料蒐集與前處理，包含欄位整理、資料轉換及變數建立，以提升資料品質與分析效率；後續透過線性迴歸模型分析年份與離婚比例之關聯性，進一步探討研究期間內離婚比例之變化趨勢，以提升分析結果之可靠性與研究結論之參考價值。



區塊說明: Generate Attributes

- 保留原始欄位
- 新增新的欄位
- 不會直接覆蓋原資料

我們想做離婚率的調查，但原始資料中並沒有提供，於是我們利用現有的資料算出離婚率，並利用 Generate Attributes 新增離婚率的欄位。



區塊說明: Select Attributes

- 選擇要保留的欄位
- 篩掉不需要的資料欄做特徵選擇 (feature selection) 讓模型只看特定變數

變數分配情況:

- 選入的變數

1. 年份、新北市行政區：因為我們要觀察的是每年 新北市各行政區


的離婚率，所以年份和新北市行政區需要保留。

2. 離婚比例：這是我們要研究的變化結果，這也需要保留。

- 剔除的變數

1. 喪偶男 (女)、有偶男 (女)、未婚男 (女)、總計等

這些欄位因為我們觀察離婚率時並不會用到，屬於無效 (沒意義) 的資料，所以這些通通剔除。




區塊說明:Set Role

選定變數後，接著需要明確指定系統：哪個欄位是模型要進行預測的目標。

設定內容：

- Attribute Name(屬性名稱): 離婚比例、年份、新北市行政區
- Target Role(目標角色): label、regular
 1. Label 代表模型要學習、要預測的目標欄位 (Target)，像是方程式中的答案、Y 值，我們想知道每年的離婚比例，於是要將離婚比例設定為 Label。
 2. Regular 代表一般資料欄位 (特徵)，像是方程式中的 X 變數，也是可以給模型參考的資料，所以年份和新北市行政區都需設定為 Regular。




區塊說明:Nominal to Numerical

把文字類別資料 (Nominal) 轉換成數字資料 (Numerical)


設定完屬性後我們就要來轉換資料了，因為原始資料只代表文字並不

能計算所以需要用 Nominal to Numerical 把文字類資料轉成數字類，才能開始計算我們想要的離婚率。



區塊說明：Split Data

Split Data 的目的是檢查模型是不是「真的會」，而不是「只是背答案」。於是我們分配 70%的資料來訓練模型，30%的資料來測試模型。



區塊說明：Linear Regression

常見的「預測模型」，主要用來分析「數值型資料之間的關係」，並根據已知資料去預測未來數。

功能:

1. 建立預測模型

可以根據歷史資料預測未來數值。

2. 分析變數影響程度

哪個變數對結果影響最大。


3. 找出資料之間的關係

正相關、負相關

4. 進行數值型預測

當放入 Linear Regression Operator 後，我們會得到：

1. 自動訓練模型
2. 計算迴歸係數
3. 建立預測公式
4. 產生預測結果
5. 顯示誤差分析



區塊說明：Apply Model (套用模型)

把已經訓練完成的模型，真正套用到資料上進行預測

當已經建立好模型後 (例如 Linear Regression、Decision Tree 等)，

Apply Model 會：

讀取模型、將模型套用到資料、產生預測結果


Apply Model 的輸入與輸出：

輸入：

- mod (Model) 輸入端：接收來自 Linear Regression 訓練好的「預測公式」。
- unl (Unlabelled Data) 輸入端：接收來自 Split Data 分出來的 30% 測試資料。

輸出：

- unl (Unlabelled Data) 輸出端：除了會出現原始資料外還會多新增一個 prediction 欄位，為模型預測後的結果。



區塊說明：Performance

主要功能用於評估線性迴歸模型預測效果的工具，可透過多項評估指標檢視模型表現，進一步判斷模型是否具有良好的預測能力與解釋能力，並作為比較不同模型設定。

主要指標:

- RMSE(Root Mean Squared Error)均方根誤差
- MAE(Mean Absolute Error)平均絕對誤差
- Correlation(相關係數)
- Squared Correlation (判定係數 R^2)

四、資料採礦結果說明

(一) ExampleSet (Split Data) 資料切割

Row No.	離婚比例	新北市行政...	新北市行政...	新北市行政...	新北市行政...	新北市行政...	新北市行政...	新北市行政...	新北市行政...	新北市行政...
1	8.541	0	0	1	0	0	0	0	0	0
2	8.028	0	0	0	1	0	0	0	0	0
3	7.476	0	0	0	0	0	1	0	0	0
4	8.325	0	0	0	0	0	0	1	0	0
5	8.177	0	0	0	0	0	0	0	0	1
6	8.620	0	0	0	0	0	0	0	0	0
7	8.522	0	0	0	0	0	0	0	0	0
8	8.423	0	0	0	0	0	0	0	0	0
9	7.325	0	0	0	0	0	0	0	0	0
10	7.058	0	0	0	0	0	0	0	0	0
11	8.403	0	0	0	0	0	0	0	0	0
12	7.957	0	0	0	0	0	0	0	0	0
13	9.346	0	0	0	0	0	0	0	0	0
14	9.413	0	0	0	0	0	0	0	0	0
15	8.850	0	0	0	0	0	0	0	0	0
16	10.873	0	0	0	0	0	0	0	0	0

說明：此圖主要顯示進入線性迴歸模型中的資料欄位與數值。此步驟的目的在於將類別型資料，轉換成可供線性迴歸分析使用的數值型資料，使模型能夠進一步分析不同行政區對結果變數的影響程度。

結果：透過資料切割，可看出新北市不同行政區的離婚比例。

(二) Linear Regression (線性迴歸係數結果)

LinearRegression (Linear Regression)

AttributeWeights (Linear Regression)

ExampleSet (Split Data)

Result History

ExampleSet (Apply Model)

PerformanceVector (Performance)

Data

Description

Annotations

Attribute	Coefficient	Std. Error	Std. Coefficient	Tolerance	t-Stat	p-Value	Code
新北市行政區 = 新北市	-0.291	0.103	-0.043	0.656	-2.823	0.006	***
新北市行政區 = 板橋區	-0.961	0.097	-0.155	0.621	-9.898	0	****
新北市行政區 = 三重區	0.295	0.102	0.044	0.665	2.880	0.005	***
新北市行政區 = 中和區	-0.276	0.097	-0.045	0.625	-2.857	0.005	***
新北市行政區 = 永和區	-0.876	0.122	-0.101	0.766	-7.156	0.000	****
新北市行政區 = 新莊區	-0.905	0.093	-0.157	0.589	-9.776	0.000	****
新北市行政區 = 新店區	0.052	0.102	0.008	0.665	0.509	0.612	
新北市行政區 = 樹林區	-0.481	0.122	-0.055	0.765	-3.928	0.000	****
新北市行政區 = 三峽區	0.463	0.110	0.061	0.712	4.198	0.000	****
新北市行政區 = 淡水區	0.366	0.102	0.054	0.665	3.570	0.001	****
新北市行政區 = 汐止區	0.654	0.110	0.087	0.711	5.931	0.000	****
新北市行政區 = 瑞芳區	2.303	0.103	0.340	0.656	22.322	0	****
新北市行政區 = 土城區	0.086	0.102	0.013	0.665	0.840	0.403	
新北市行政區 = 蘆洲區	-0.597	0.103	-0.088	0.660	-5.804	0.000	****
新北市行政區 = 五股區	0.591	0.112	0.078	0.696	5.298	0.000	****
新北市行政區 = 泰山區	-0.958	0.097	-0.154	0.622	-9.874	0	****
新北市行政區 = 林口區	-1.485	0.103	-0.219	0.662	-14.463	0	****

● Coefficient (迴歸係數)

說明：代表「變數」對「目標變數」的影響方向與大小。

判斷：正值代表該行政區的離婚率相對較高；負值代表該行政區的離婚率相對較低。絕對值越大，代表影響程度越高。

結果：不同行政區變數對目標變數具有不同方向的影響，可看出不同地區之間的差異。

● Std. Error (標準誤差)

說明：用來衡量模型「估計值」的穩定程度。

判斷：數值越小，代表估計越穩定。

結果：本研究中，多數標準誤數值約介於 0.09 至 0.14 之間。表示模型估計結果相對穩定，模型分析具有一定可信度。

● Std. Coefficient (標準化係數)

說明：標準化係數是將不同變數轉換為相同尺度後的結果，用來比較「各變數的重要程度」。

判斷：絕對值越大，代表變數越重要；接近 0 則代表影響較小。

結果：因為標準化係數已消除不同單位造成的差異，所以可以直接比較哪些變數可能成為模型中的主要影響因素。

● Tolerance (容忍度)

說明：容忍度用來檢查模型是否存在多重共線性問題。若變數之間過度相似，可能導致模型不穩定。

判斷：數值越接近 1，代表共線性問題越低；數值過低則可能存在高度相關。

結果：本研究中的數值並未過低，表示模型未出現明顯多重共線性問題，因此模型穩定性尚可。

● T-Stat (t 統計量)

說明：用來檢驗變數是否對模型具有顯著影響。

判斷：t 值絕對值越大，代表影響越顯著；若接近 0，則代表影響較小。

結果：圖中許多變數的 t 值絕對值較高，代表這些變數對模型具有明顯影響力。

- P-Value (顯著性)

說明：用來判斷變數是否具有統計顯著性。

判斷：P-value < 0.05：具有顯著影響；P-value > 0.05：影響不明顯。

結果：本研究中多數變數的 P-value 接近 0 或小於 0.05。代表多數變數對目標變數具有統計上的顯著影響。

(三) Attribute Weights (屬性權重)

attribute	weight
新北市行政區 = 新北市	-0.291
新北市行政區 = 板橋區	-0.961
新北市行政區 = 三重區	0.295
新北市行政區 = 中和區	-0.276
新北市行政區 = 永和區	-0.876
新北市行政區 = 新莊區	-0.905
新北市行政區 = 新店區	0.052
新北市行政區 = 樹林區	-0.481
新北市行政區 = 鶯歌區	0
新北市行政區 = 三峽區	0.463
新北市行政區 = 淡水區	0.366
新北市行政區 = 汐止區	0.654
新北市行政區 = 瑞芳區	2.303
新北市行政區 = 土城區	0.086
新北市行政區 = 蘆洲區	-0.597
新北市行政區 = 五股區	0.591
新北市行政區 = 泰山區	-0.958

說明：顯示各變數在線性迴歸模型中的影響方向與影響程度。

判斷：正值代表該行政區與離婚比例呈正向關係，模型預測其離婚比例可能較高；負值代表該行政區與離婚比例呈負向關係，模型預測其離婚比例可能較低。權重絕對值越大，表示該行政區對模型之影響程度越明顯。

權重的絕對值越大，表示該變數對模型的影響力越明顯。


結果：可以初步了解哪些行政區變數對研究目標的影響較顯著。

(四) PerformanceVector (模型績效結果)

PerformanceVector

```
PerformanceVector:  
root_mean_squared_error: 0.224 +/- 0.000  
squared_error: 0.050 +/- 0.095
```

- Root Mean Squared Error (RMSE) = 0.224 +/- 0.000




說明：均方根誤差是用來衡量模型「預測值」與「實際值」之間誤差大小的指標。

判斷：數值越接近 0，代表模型預測效果越好。

結果：本研究的 RMSE 為 0.224，且誤差波動值為 ± 0.000 ，代表模型整體預測誤差相對穩定，模型對資料具有一定程度的解釋能力與預測效果。

- Squared Error = 0.050 +/- 0.095



說明：平方誤差主要用來衡量模型「預測值」與「實際值」之差距。

判斷：數值越小表示模型越準確。

結果：代表模型平均平方誤差約為 0.050，而 ± 0.095 則表示誤差可能存在的波動範圍。顯示模型整體誤差維持在低水準，代表資料配適情況良好，建立之線性迴歸模型具有不錯的穩定性與可信度。

五、遇到的問題和建議改進的方法

(一)原始資料為絕對人數，不同行政區人口規模差異造成比較偏差


問題說明:

原始資料內容主要為各行政區婚姻狀況之「人數統計資料」，包含未婚、有偶、離婚及喪偶等人口數。然而，新北市各行政區人口規模存在明顯差異，例如板橋區人口遠高於坪林區、石碇區等行政區，若直接以絕對人數進行分析，容易導致人口較多行政區產生較大的影響效果，而無法公平比較各行政區婚姻狀況變化趨勢。

改進方法:

為降低人口基數差異造成之影響，本模型中重新透過

Generate Attributes 建立比例型指標，如下圖所示。



透過比例化處理，可提升不同行政區之間比較的合理性，使模型分析更符合研究目的。

(二)原始資料之離婚合計欄位定義不完整，導致模型無法正確分析

問題說明:

經檢視原始資料後，發現「離婚合計」欄位未完整納入同性離婚人口，若直接採用可能低估實際離婚情況。

N	O	P	Q	R
離婚合計	離婚男	離婚男(同性)	離婚女	離婚女(同性)
322499.0...	144579.0...	0.000	177920.0...	0.000
330855.0...	148202.0...	12.000	182653.0...	17.000

改進方法:

因此在模型建立過程中利用 Generate Attributes 建立「離婚比例」指標，並重新設定 Label(目標變數)，使模型能以離婚比例作為主要分析目標，提升模型解釋能力與研究結果可信度。


attribute name	target role
離婚比例	label

(三)類別型資料需進行數值化轉換

問題說明:


行政區屬於類別型(Nominal)資料，無法直接投入線性迴歸模型分析。

若未進行資料轉換，模型無法正確估計各行政區之影響。



改進方法:

在模型建立過程中使用 Nominal to Numerical 將行政區轉換為 Dummy Variables，使類別資料可納入迴歸模型分析，提升模型運作完整性。



模型檢驗與改善:


(一)資料切分比例可能影響模型穩定性

問題說明:

本模型中過程中使用 Split Data 將資料分為訓練資料(Training Data)與測試資料(Testing Data)，並建立線性迴歸模型進行分析。然而，若僅進行單次資料切分，不同切分結果可能導致模型訓練過程受到

樣本分配影響，使模型評估結果產生差異，進而影響模型穩定性與分析結果之可信度。


由於研究資料包含不同年份與行政區資料，若資料分配不均，可能使某部分資料特徵於訓練或測試階段呈現不足，進而影響模型預測能力。




改進方法:

在模型中加入 Cross Validation(交叉驗證)方法，透過多次資料切分與模型訓練程序，降低單次資料切所造成之誤差影響，提高模型穩定性與結果可靠性。

此外，亦可透過多次抽樣方式比較模型表現，使結果更具一致性與代表性。





加入 Cross Validation 前/後對比:

Attribute	Coefficient	Attribute	Coefficient
新北市行政區 = 蘆...	-0.597	新北市行政區 = 蘆...	-0.299
新北市行政區 = 五...	0.591	新北市行政區 = 五...	0.894
新北市行政區 = 泰...	-0.958	新北市行政區 = 泰...	-0.680
新北市行政區 = 林...	-1.485	新北市行政區 = 林...	-1.156
新北市行政區 = 深...	0.162	新北市行政區 = 深...	0.414
新北市行政區 = 石...	1.210	新北市行政區 = 石...	1.486
新北市行政區 = 坪...	-0.608	新北市行政區 = 坪...	-0.362
新北市行政區 = 三...	1.668	新北市行政區 = 三...	1.917
新北市行政區 = 八...	1.243	新北市行政區 = 石...	0.275
新北市行政區 = 平...	2.128	新北市行政區 = 八...	1.532
新北市行政區 = 雙...	1.409	新北市行政區 = 平...	2.313
新北市行政區 = 貢...	2.017	新北市行政區 = 雙...	1.676
新北市行政區 = 金...	1.055	新北市行政區 = 貢...	2.162
新北市行政區 = 萬...	2.584	新北市行政區 = 金...	1.354
新北市行政區 = 烏...	2.308	新北市行政區 = 萬...	2.815
年份	0.199	新北市行政區 = 烏...	2.554
		年份	0.200

root_mean_squared_error

root_mean_squared_error: 0.224 +/- 0.000

root_mean_squared_error

root_mean_squared_error: 0.211 +/- 0.030 (micro average: 0.213 +/- 0.000)

加入 Cross Validation 後，各變數係數估計結果與原始模型差異有限，尤其年份變數係數變化幅度極小(0.199→0.200)，顯示模型結果具有一致性，不易受單次資料切割方式影響。同時，模型的 RMSE 由 0.224 降低

至 0.211，整體平均誤差 (micro average) 為 0.213，顯示模型預測誤差略有下降。

綜合結果可知，導入 Cross Validation 後，模型在不同資料切分情況下仍維持相對穩定之表現，有助於提升模型評估結果之穩定性與可靠性。

六、結論

- 研究結果中，多數變數之 P-value 小於 0.05，代表行政區與年份對離婚比例具有一定影響，不是隨機結果。模型之 RMSE 為 0.224，代表模型整體誤差較低。
- 在資料處理過程中，為避免人口規模差異影響，本研究建立「離婚比例」指標進行分析，使各行政區之間能夠進行較公平的比較。
- 綜合結果發現，尤其在 2024 年，萬里區和瑞芳區的離婚比例較高，逐年也有增加的趨勢。
- 本研究利用資料採礦與線性迴歸分析方法，探討新北市各行政區離婚比例之變化趨勢。透過本次研究，不僅能更了解不同地區離婚比例之差異，也能進一步熟悉資料前處理、模型建立與模型評估等資料採礦分析流程，作為未來相關研究與資料分析之參考。